

Sistema Automatizado de Control Vehicular Basado en TinyML y Edge Computing para la Sede Tintal de la ETITC

Ing. Laura Juliana Huertas Huertas

Ing. Hernán Camilo Guerrero Forero

Asesor:

Ing.

Escuela Tecnológica Instituto Técnico Central

Especialización en Instrumentación Industrial

Proyecto Integrador II

Bogotá D.C.

2026

Resumen

El presente proyecto propone el diseño e implementación de un sistema automatizado de ingreso y salida vehicular en la sede Tintal de la ETITC, basado en el uso de redes neuronales ligeras ejecutadas en el borde (Edge Computing / TinyML). Actualmente, el proceso de control se realiza de forma manual, generando demoras y limitada trazabilidad. La propuesta busca desarrollar un prototipo funcional sobre un sistema embebido, capaz de reconocer placas vehiculares mediante una red neuronal ligera optimizada para microcontrolador. Esto reducirá los tiempos de ingreso y fortalecerá la confiabilidad del sistema sin recurrir a infraestructura costosa.

Palabras clave: TinyML, Edge Computing, control vehicular, microcontroladores, automatización.

Índice

Introducción	6
Justificación	7
Planteamiento del Problema	9
Objetivos y Pregunta de Investigación	11
Objetivo General	11
Objetivos Específicos	11
Pregunta de Investigación	12
Alcance y Delimitaciones	12
Marco Teórico	13
Sistemas de Parqueo Inteligente (Smart Parking)	13
Fog Computing y Edge Computing	13
Visión por Computador	14
TinyML y Redes Neuronales Ligeras	14
Microcontroladores en Automatización	14
Impresión 3D en Prototipado Rápido	15
Estado del Arte	15
Arquitecturas de Procesamiento: Cloud, Fog y Edge	15
Sistemas Comerciales y Propuestas Académicas de Parqueo Inteligente	16
TinyML, Edge Impulse y Avances en IA Embebida	17
Limitaciones Identificadas en el Estado del Arte	17
Cómo se Posiciona el Presente Proyecto	18

Diseño Metodológico	20
Enfoque Metodológico	20
Variables del Estudio	20
Correspondencia entre Objetivos, Fases y Actividades	20
Fase 1: Diseño de Arquitectura y Hardware	21
Actividad 1.1: Selección de la plataforma embebida	22
Actividad 1.2: Selección de la red de sensores de activación	23
Actividad 1.3: Diseño mecánico y ensamblaje profesional	23
Actividad 1.4: Propuesta de escalabilidad energética (Sistema Fotovoltaico) .	23
Fase 2: Modelado TinyML y Etapa de Señalización	24
Actividad 2.1: Estrategia de curaduría y recolección de datos	25
Actividad 2.2: Entrenamiento y optimización en Edge Impulse	25
Actividad 2.3: Diseño de la etapa electrónica y señalización visual	26
Fase 3: Implementación del Módulo de Trazabilidad	27
Actividad 3.1: Configuración de lista blanca	27
Actividad 3.2: Registro de eventos (Logs)	27
Fase 4: Pruebas, Validación y Evaluación	27
Actividad 4.1: Pruebas en entorno controlado	27
Actividad 4.2: Evaluación comparativa de eficiencia	27
Resultados Preliminares: Entrenamiento del Modelo TinyML	29
Análisis de las métricas del modelo	29
Validación lógica y próximos pasos	30
Presupuesto del Prototipo	31
Cronograma de Actividades	31

Índice de figuras

1.	Interfaz de adquisición de datos en Edge Impulse mostrando el etiquetado (bounding boxes) de las placas de motocicletas.	25
2.	Configuración del bloque de procesamiento y detección de objetos (FOMO) optimizado para el microcontrolador.	26
3.	Algoritmo lógico de reconocimiento y control de acceso.	28
4.	Métricas de validación y matriz de confusión del modelo cuantizado (Int8). .	29
5.	Curva de pérdida (Loss) durante el entrenamiento de la red neuronal a lo largo de 60 épocas.	30

Índice de Tablas

1.	Comparativa de enfoques de procesamiento en sistemas inteligentes de parqueo	19
2.	Matriz de alineación metodológica: Objetivos, Fases y Actividades (Actualizada)	21
3.	Matriz de decisión para la selección de la plataforma embebida	22
4.	Proyección de costos para escalabilidad con sistema fotovoltaico autónomo .	24
5.	Presupuesto estimado para el prototipo funcional (MVP)	31
6.	Cronograma de ejecución del proyecto (Semanas)	32

Introducción

El aumento constante del parque automotor a nivel global ha generado nuevos desafíos en la gestión de accesos y estacionamientos institucionales. La carencia de sistemas eficientes de control provoca congestión, tiempos de espera prolongados y dificultades logísticas, problemáticas que suelen enfrentarse mediante infraestructura automatizada de alto costo o personal operativo permanente, limitando su viabilidad en entornos con restricciones presupuestales (Alam et al., 2023). A este escenario se suma la inminente transición hacia la movilidad eléctrica, la cual exige que las infraestructuras universitarias modernicen sus accesos como paso habilitador hacia la consolidación de campus inteligentes (Efthymiou et al., 2017; Leurent & Windisch, 2011; Subash & Narmadhai, 2025).

En el ámbito educativo, los sistemas tradicionales —basados en verificación manual o mecanismos electromecánicos convencionales— generan cuellos de botella críticos. De acuerdo con la literatura sobre flujos de tránsito, la validación manual introduce una alta variabilidad en el tiempo de servicio, produciendo filas que pueden oscilar entre uno y cinco minutos por vehículo en horas pico, afectando directamente la puntualidad académica y la eficiencia del recinto (Federal Highway Administration (FHWA), 2019).

Para mitigar estas deficiencias, diversas investigaciones han explorado tecnologías emergentes. Celaya-Echarri et al. (2020) propusieron un sistema descentralizado basado en *fog computing* para procesar datos cerca de la fuente, reduciendo la latencia; mientras que Marshoodulla y Saha (2024) desarrollaron un marco de análisis mediante IoT para la gestión dinámica del flujo. No obstante, como señalan Alam et al. (2023), estas soluciones presentan serias limitaciones de escalabilidad económica al depender de servidores dedicados y conectividad constante.

A nivel regional, implementaciones como el sistema RFID de Olivares (2011) o el reconocimiento de placas propuesto por Valeo et al. (2020) en Argentina demostraron la efectividad de la automatización, pero ratificaron que la dependencia de cámaras industria-

les o infraestructura física robusta sigue siendo una barrera de adopción para instituciones públicas.

En contraste, investigaciones recientes como la de Zheng et al. (2025) evidencian que las arquitecturas de redes neuronales ligeras pueden ejecutarse eficientemente en dispositivos de recursos restringidos, reduciendo drásticamente el consumo energético y la inversión requerida.

A partir de esta revisión, se identifica una brecha tecnológica: la ausencia de propuestas orientadas a entornos educativos que integren reconocimiento automático de placas mediante modelos de aprendizaje automático ligero ejecutados directamente en microcontroladores (*Edge Computing*), eliminando la dependencia de servidores externos.

En respuesta a esta necesidad, el presente proyecto desarrolla un sistema automatizado de control vehicular basado en *TinyML* para la sede Tintal de la ETITC. El sistema ejecuta la inferencia directamente en un dispositivo embebido con cámara integrada, gestionando una lista de autorización local para generar una señal de acceso inmediata. Con esta implementación, se busca demostrar la viabilidad técnica de la inteligencia artificial en el borde para optimizar los tiempos de ingreso y la trazabilidad, ofreciendo una solución escalable y económicamente sostenible.

Justificación

El proceso actual de control vehicular en la sede Tintal de la ETITC opera mediante verificación manual de documentos, lo que genera congestión en horas pico y una total ausencia de registros históricos. La literatura advierte que la dependencia exclusiva de la intervención humana en procesos administrativos incrementa la probabilidad de error y anula la trazabilidad institucional. Al respecto, Macias Aleman (1996) documenta que la digitalización es el único mecanismo efectivo para mitigar fallas operativas y garantizar un flujo de información constante. En el contexto educativo, Oloriz et al. (2022) demostraron que la

automatización de procesos universitarios democratiza la disponibilidad de la información, permitiendo auditorías y decisiones estratégicas basadas en datos reales y no en suposiciones.

Si bien existen múltiples investigaciones que proponen optimizar el control vehicular mediante IoT y *fog computing* —como el sistema de parqueo inteligente implementado por Celaya-Echarri et al. (2020), el cual reduce la latencia procesando los datos cerca de la fuente—, estas arquitecturas presentan una barrera crítica para su adopción en instituciones de educación pública: el costo de implementación y mantenimiento.

En su revisión exhaustiva sobre sistemas inteligentes de parqueo, Alam et al. (2023) concluyen que el principal obstáculo para la masificación tecnológica es el alto costo de infraestructura. Un sistema comercial estándar de reconocimiento de placas (LPR) requiere cámaras industriales y servidores dedicados, lo que implica una inversión inicial que oscila entre los \$2,000 y \$4,000 USD por punto de acceso, sumado a los gastos recurrentes de licenciamiento de software y mantenimiento especializado. Para una institución con recursos limitados, esta carga financiera resulta insostenible.

Por otro lado, las soluciones basadas en identificación por radiofrecuencia (RFID), analizadas por Olivares (2011), presentan un desafío logístico y económico diferente centrado en el usuario. Aunque la inversión en lectoras es alta, el verdadero problema radica en los *tags* o tarjetas de acceso, cuyo costo oscila entre \$2 y \$5 USD por unidad. En un entorno universitario caracterizado por una población estudiantil rotativa, la gestión, reposición por pérdida y entrega continua de miles de tarjetas genera un gasto operativo (OPEX) recurrente que desborda los presupuestos de bienestar universitario.

Frente a este escenario de costos prohibitivos, tecnologías emergentes como *TinyML* permiten ejecutar modelos de inteligencia artificial directamente en microcontroladores de bajo costo (inferiores a \$50 USD). Warden y Situnayake (2020) demuestran que es posible realizar inferencias de modelos complejos en estos dispositivos sin necesidad de conexión a servidores externos. Esto valida los hallazgos de Zheng et al. (2025), quienes lograron un reconocimiento vehicular eficiente eliminando la dependencia de la nube. Al procesar las

imágenes localmente mediante *Edge Computing*, se suprimen los costos asociados a servidores, se minimiza el consumo de ancho de banda y se evita la adquisición de hardware industrial (Satyanarayanan, 2017).

Por consiguiente, implementar un sistema de control vehicular mediante *TinyML* y *Edge Computing* representa una alternativa técnicamente robusta y económicamente sostenible para la ETITC. Esta solución proyecta reducir la inversión inicial en más de un 90 % respecto a las alternativas comerciales, automatiza el proceso sin generar costos recurrentes por usuario y garantiza una trazabilidad total del acceso vehicular.

Planteamiento del Problema

En la sede Tintal de la Escuela Tecnológica Instituto Técnico Central (ETITC), el control de ingreso y salida vehicular se realiza mediante verificación manual de documentos por parte del personal de seguridad. Este procedimiento exige que cada vehículo se detenga por completo mientras se valida la identidad del conductor y su respectiva autorización. Dicha dinámica incrementa exponencialmente los tiempos de espera y genera congestión en los accesos durante las franjas horarias de mayor afluencia, ocasionando filas que impactan el inicio de las actividades académicas.

A falta de instrumentación previa en el sitio, se ha realizado una modelización teórica del sistema manual fundamentada en los estándares de la *Federal Highway Administration* (FHWA) y en estudios de flujo vehicular universitario (Al-Jaleel & Al-Sultan, 2022; Federal Highway Administration (FHWA), 2019). Según estos referentes, el ciclo de validación manual (que incluye la detención, interacción con el guarda, búsqueda del documento y registro) consume un tiempo de servicio promedio (μ) de entre 21 y 45 segundos por vehículo.

Bajo un modelo de teoría de colas M/M/1, esto implica que el sistema manual posee una capacidad máxima teórica de apenas 2 vehículos por minuto. En horas pico, donde la tasa de llegada (λ) supera esta capacidad (e.g., $\lambda > 2,5$ vehículos/minuto), el factor de

utilización del sistema (ρ) excede el 100 %. Este desbordamiento explica matemáticamente la formación de colas infinitas y la inestabilidad operativa observada en la sede Tintal. A esto se suma que la fatiga operativa del personal, derivada de la verificación visual continua, incrementa la probabilidad de error y vulnera la seguridad del recinto (American Association of Motor Vehicle Administrators (AAMVA), 2021).

Experiencias documentadas evidencian que los procesos de validación estrictamente manuales en accesos institucionales generan ineficiencias operativas crónicas, carecen de trazabilidad y dependen de forma absoluta de la intervención humana (Macias Aleman, 1996; Oloriz et al., 2022). Al carecer de registros históricos digitalizados, la institución pierde la capacidad de realizar análisis de gestión o auditorías de seguridad.

En años recientes, múltiples investigaciones han demostrado que la automatización de estacionamientos mediante el Internet de las Cosas (IoT), *fog computing* o sistemas RFID mejora sustancialmente la gestión de los accesos (Celaya-Echarri et al., 2020; Marshoodulla & Saha, 2024; Olivares, 2011). Sin embargo, estas soluciones presentan barreras de adopción críticas para las instituciones educativas públicas, tales como altas inversiones en infraestructura física, dependencia de servidores externos y necesidad de adecuaciones civiles o cableado especializado (Alam et al., 2023; Valeo et al., 2020).

En contraste, tecnologías emergentes como las *redes neuronales ligeras* habilitan la ejecución de modelos de inteligencia artificial directamente en microcontroladores de bajo costo, eliminando la necesidad de procesamiento centralizado (Zheng et al., 2025). Esta capacidad contrasta fuertemente con los sistemas LPR existentes que exigen servidores dedicados o cámaras industriales, los cuales inflan los costos y bloquean su implementación en contextos académicos con restricciones presupuestales (Alam et al., 2023).

A partir de este diagnóstico técnico y matemático, se identifican las siguientes limitaciones críticas en el proceso actual de la sede Tintal:

- **Ineficiencia operativa:** El tiempo de servicio manual (μ) provoca una saturación del sistema ($\rho > 100\%$) y congestión en los accesos.

- **Ausencia de trazabilidad:** La inexistencia de un registro digital impide el análisis estadístico y la toma de decisiones basada en datos.
- **Vulnerabilidad humana:** El proceso está sujeto a tiempos de validación altamente variables y a errores por fatiga visual del operador.

Lo anterior evidencia la necesidad imperativa de un sistema automatizado de validación vehicular que reduzca los tiempos de ingreso, minimice la intervención humana y garantice la trazabilidad de los accesos, todo ello estructurado sobre una arquitectura tecnológicamente viable y económicamente sostenible para la ETITC.

Objetivos y Pregunta de Investigación

Objetivo General

Desarrollar un sistema automatizado de ingreso y salida de vehículos automotores en el parqueadero universitario de la sede Tintal de la ETITC, basado en reconocimiento de placas mediante modelos de *redes neuronales ligeras* desplegados sobre *Sistemas Embebidos*, mediante redes de sensores y sistemas electrónicos de potencia, con el propósito de optimizar el control de ingreso y salida vehicular, mejorar la trazabilidad de los registros y reducir la dependencia de procedimientos manuales.

Objetivos Específicos

- Implementar un sistema de validación de credenciales vehiculares y estudiantiles mediante redes de sensores y modelos de *redes neuronales ligeras* ejecutados en dispositivos embebidos.
- Desplegar un modelo de reconocimiento de placas vehiculares capaz de operar con baja latencia, mediante procesamiento local en el dispositivo y capaz de activar un actuador mediante sistemas electrónicos de potencia.

- Diseñar un módulo de gestión de trazabilidad que permita almacenar, consultar y analizar los registros de ingreso y salida de vehículos de forma segura y confiable.

Pregunta de Investigación

¿De qué manera un sistema embebido basado en redes neuronales ligeras y Edge Computing puede mejorar la eficiencia y trazabilidad del control vehicular en la sede Tintal de la ETITC, reduciendo los costos de infraestructura respecto a los métodos tradicionales?

Alcance y Delimitaciones

Para garantizar la viabilidad técnica del desarrollo y la correcta evaluación del prototipo funcional (Producto Mínimo Viable - MVP) dentro de las restricciones de memoria de la plataforma embebida, el alcance inicial del proyecto se delimita de la siguiente manera:

- **Focalización vehicular:** El sistema de visión artificial y la red neuronal se entrenarán de manera exclusiva para la detección y reconocimiento de **placas de motocicletas**. Esta delimitación responde a las diferencias morfológicas y geométricas que presentan estas placas frente a las de automóviles convencionales, lo que requiere un enfoque especializado en el *dataset* para asegurar una alta tasa de aciertos en la inferencia local.
- **Entorno de validación:** Aunque el diseño se proyecta para la Sede Tintal, las pruebas de validación del prototipo se ejecutarán en la Sede Centro de la ETITC, simulando las condiciones de iluminación y distancia requeridas.
- **Actuación física:** La validación de acceso exitoso se representará mediante una etapa de señalización lumínica (LED de estado), omitiendo la instalación de barreras mecánicas o talanqueras reales durante esta fase de demostración tecnológica.

Marco Teórico

Sistemas de Parqueo Inteligente (Smart Parking)

Los sistemas de parqueo inteligente son soluciones tecnológicas orientadas a optimizar el uso de espacios de estacionamiento mediante la automatización del proceso de monitoreo, detección y gestión de disponibilidad. Su objetivo es reducir la búsqueda de espacios, descongestionar zonas urbanas y disminuir el consumo de combustible asociado a la circulación sin destino (Alam et al., 2023). Según Alam et al. (2023), los sistemas de parqueo inteligente combinan sensores, conectividad IoT y analítica de datos para gestionar el flujo vehicular en tiempo real.

Celaya-Echarri et al. (2020) proponen un sistema de parqueo inteligente basado en *fog computing*, demostrando que el procesamiento cercano al usuario reduce el tiempo de respuesta frente a soluciones dependientes exclusivamente de servidores en la nube. Marshoodulla y Saha (2024) complementan esta visión con un enfoque SDN-IoT, donde el flujo de datos se controla dinámicamente, mejorando la eficiencia del sistema.

Fog Computing y Edge Computing

El *fog computing* es una arquitectura distribuida que permite procesar datos cerca de su origen, en lugar de enviarlos a servidores remotos. Celaya-Echarri et al. (2020) demuestran que esta arquitectura reduce la latencia, minimiza la congestión en la red y mejora el rendimiento de aplicaciones IoT en tiempo real. Mientras que la nube requiere enviar información a un servidor central, el *fog computing* utiliza nodos intermedios que permiten decisiones más rápidas y eficientes.

El *edge computing* comparte el principio de procesamiento local, pero lo enfoca directamente en el dispositivo final (sensores, cámaras o microcontroladores). Según Zheng et al. (2025), la ejecución de modelos de visión artificial directamente en el borde reduce el

flujo de datos transmitidos y disminuye los costos operativos al eliminar infraestructura de servidores centralizados.

Visión por Computador

La visión por computador es una rama de la inteligencia artificial cuyo propósito es permitir que una máquina interprete información visual del entorno —imágenes o video— y tome decisiones basadas en dicha interpretación. Aplicada a sistemas de parqueo inteligente, permite identificar objetos (vehículos), reconocer estados (espacio ocupado o libre) y ejecutar acciones automatizadas en consecuencia.

Zheng et al. (2025) implementaron redes neuronales ligeras para clasificación de imágenes en sistemas de estacionamiento, demostrando que es posible realizar procesamiento en tiempo real incluso en hardware embebido.

TinyML y Redes Neuronales Ligeras

TinyML es una disciplina que permite ejecutar modelos de aprendizaje automático en microcontroladores y dispositivos de bajo consumo energético. De acuerdo con Daniel y Ram (2022), el uso de TinyML reduce la necesidad de transmitir datos hacia la nube, disminuyendo costos y aumentando la seguridad de los datos.

Edge Impulse provee herramientas para entrenar modelos y exportarlos directamente a microcontroladores sin necesidad de infraestructura de cómputo avanzada (Edge Impulse Inc., 2025). Esta capacidad permite desarrollar prototipos funcionales en contextos académicos con recursos limitados.

Microcontroladores en Automatización

Los microcontroladores son dispositivos electrónicos programables diseñados para controlar sistemas embebidos. Su uso en automatización educativa ha sido ampliamente

estudiado. Candelas Herias et al. (2015) muestran que plataformas basadas en microcontroladores facilitan el aprendizaje de robótica, control y electrónica en entornos formativos, permitiendo la experimentación práctica a bajo costo. Su integración con sensores y actuadores hace viable el desarrollo de sistemas automáticos que reaccionen a condiciones detectadas mediante visión artificial.

Impresión 3D en Prototipado Rápido

La fabricación aditiva en impresión 3D permite desarrollar prototipos físicos de manera rápida y económica. Esta metodología reduce los tiempos de iteración en diseño y evita los costos de manufactura tradicional, lo que resulta ideal para proyectos de automatización que requieren ajustes frecuentes en componentes mecánicos.

Estado del Arte

El estado del arte reúne las soluciones y enfoques más relevantes en automatización de accesos vehiculares, con especial atención en arquitecturas de computación distribuida (cloud, fog, edge), sistemas comerciales de parqueo y las últimas aportaciones en TinyML para ejecución en dispositivos embebidos.

Arquitecturas de Procesamiento: Cloud, Fog y Edge

Las arquitecturas basadas en la nube (cloud) concentran el procesamiento en centros remotos, ofreciendo alta capacidad de cómputo y almacenamiento, pero fomentando dependencia de conectividad, aumento de latencia y mayor tráfico de red. Frente a esto, el *fog computing* propone nodos intermedios que procesan datos cerca de la fuente y reducen la latencia y el tráfico hacia la nube (Bonomi et al., 2012; Celaya-Echarri et al., 2020). Celaya-Echarri et al. (2020) evidencian que el *fog computing* es efectivo en aplicaciones de parqueo inteligente al mejorar la capacidad de respuesta en escenarios con múltiples puntos

de adquisición.

Por su parte, el *edge computing* lleva el procesamiento aún más cerca del extremo —en el propio dispositivo o en su entorno inmediato—, lo que permite inferencias en tiempo real y reduce la necesidad de ancho de banda. Satyanarayanan (2017) y Zheng et al. (2025) describen cómo la ejecución de modelos en el borde disminuye costos operativos asociados al envío continuo de datos a servidores centrales, y es adecuada para aplicaciones de visión por computador con requisitos de baja latencia.

Sistemas Comerciales y Propuestas Académicas de Parqueo Inteligente

La literatura documenta múltiples implementaciones que usan sensores, RFID, cámaras y plataformas IoT para la gestión de parqueos. Alam et al. (2023) realizan una revisión amplia y concluyen que las soluciones actuales combinan sensores de ocupación, análisis en la nube y *dashboards* para administración, aunque resaltan como desafío principal los costos de infraestructura y el mantenimiento a escala. Olivares (2011) muestra un despliegue basado en RFID que exige lectoras y etiquetas por vehículo, lo cual incrementa el costo por plaza. Valeo et al. (2020) describen sistemas de reconocimiento de matrículas basados en cámaras industriales que, aunque efectivos en precisión, presentan barreras de adopción por su costo y necesidad de calibración y mantenimiento continuo.

En el ámbito académico, Celaya-Echarri et al. (2020) y Marshoodulla y Saha (2024) proponen arquitecturas distribuidas (fog/SDN-IoT) para gestionar datos y optimizar respuesta. Estas propuestas prueban mejoras en latencia y control del flujo; sin embargo, siguen ancladas a infraestructuras que requieren inversión elevada.

TinyML, Edge Impulse y Avances en IA Embebida

La aparición de TinyML ha permitido ejecutar modelos de aprendizaje automático en microcontroladores de bajo costo, habilitando aplicaciones de visión y clasificación directamente en el dispositivo. Warden y Situnayake (2020) presentan las bases de TinyML y muestran cómo modelos cuantizados pueden correr en hardware con memoria y potencia limitadas. Estudios recientes (Daniel & Ram, 2022; Zheng et al., 2025) muestran implementaciones de reconocimiento vehicular y clasificación utilizando redes ligeras, validando su viabilidad en entornos embebidos.

Edge Impulse ofrece un flujo de trabajo práctico para TinyML: adquisición de datos, entrenamiento automático y exportación a microcontroladores, reduciendo el tiempo de desarrollo y la necesidad de conocimientos expertos en optimización de modelos (Edge Impulse Inc., 2025). Investigaciones aplicadas respaldan su eficacia en escenarios reales y educativos, facilitando la transición desde prototipo a despliegue embebido (Daniel & Ram, 2022).

Complementando lo anterior, Hossain (2020) destaca que la integración de *Embedded Machine Learning* es el futuro de las aplicaciones IoT sostenibles. Estudios de Nguyen et al. (2023) validan específicamente esta arquitectura para el reconocimiento de placas, reportando tasas de precisión superiores al 90 % y latencias inferiores a 200 ms ejecutando modelos ligeros en dispositivos de borde.

Limitaciones Identificadas en el Estado del Arte

A partir de la revisión, se identifican limitaciones repetidas en la literatura:

- **Costos de infraestructura:** Soluciones basadas en cámaras industriales, servidores y sistemas RFID aumentan el costo por plaza y complican la escalabilidad (Alam et al., 2023; Olivares, 2011; Valeo et al., 2020).
- **Dependencia de conectividad:** Arquitecturas cloud pierden eficacia en escenarios con conectividad limitada o con alto volumen de eventos en tiempo real (Bonomi et al.,

2012).

- **Mantenimiento y calibración:** Equipos de visión especializados requieren calibración y mantenimiento regular, elevando costos operativos (Valeo et al., 2020).
- **Brecha en entornos educativos:** Pocas propuestas están diseñadas para instituciones con recursos limitados; muchas se centran en entornos de alto presupuesto (Alam et al., 2023).

Cómo se Posiciona el Presente Proyecto

El proyecto propuesto se posiciona en la intersección de *Edge Computing* y *TinyML* con un enfoque en replicabilidad y bajo costo para entornos educativos. La propuesta busca:

- Ejecutar inferencia de reconocimiento de placas directamente en microcontroladores, reduciendo la necesidad de servidores o cámaras industriales (Warden & Situnayake, 2020; Zheng et al., 2025).
- Emplear plataformas accesibles (Edge Impulse) durante la fase inicial para acelerar el entrenamiento y validación sin incurrir en costos de licenciamiento (Daniel & Ram, 2022; Edge Impulse Inc., 2025).
- Diseñar una arquitectura modular y escalable que permita integrar distintos sensores y actuadores sin casarse con un proveedor específico.

Tabla 1: Comparativa de enfoques de procesamiento en sistemas inteligentes de parqueo

Enfoque	Ventajas	Limitaciones
Cloud	Gran capacidad de cómputo y almacenamiento; permite modelos complejos y análisis intensivo de datos.	Latencia alta, dependencia de la conectividad y costos operativos asociados a infraestructura en la nube (Bonomi et al., 2012).
Fog	Procesamiento distribuido y reducción de latencia al ubicar nodos intermedios cerca del usuario (Celaya-Echarri et al., 2020).	Requiere infraestructura adicional (nodos fog), lo que incrementa la inversión inicial (Celaya-Echarri et al., 2020).
Edge/TinyML	Inferencia en tiempo real en el dispositivo; bajo costo de infraestructura; mejora la privacidad al no enviar datos (Warden & Situnayake, 2020; Zheng et al., 2025).	Limitaciones de memoria y capacidad de cómputo para modelos complejos; requiere optimización (Zheng et al., 2025).

En síntesis, el estado del arte presenta soluciones robustas para diversas escalas, pero ninguna atiende de forma consolidada las restricciones económicas y de mantenimiento propias de muchas instituciones educativas. El presente proyecto busca cerrar esta brecha mediante la aplicación de TinyML y Edge Computing en una arquitectura modular.

Diseño Metodológico

Enfoque Metodológico

La presente investigación se enmarca en un enfoque **cuantitativo de tipo aplicado**, con un diseño **cuasi-experimental** y alcance explicativo. El estudio consiste en el diseño, implementación y validación experimental de un prototipo funcional de control vehicular basado en redes neuronales ligeras desplegadas sobre un sistema embebido.

El propósito metodológico es evaluar la viabilidad técnica de integrar modelos de *TinyML* en un entorno real de operación, midiendo su impacto en términos de latencia, precisión y eficiencia operativa frente al procedimiento manual actualmente utilizado en la sede Tintal de la ETITC.

Variables del Estudio

Variable Independiente: Implementación de un sistema embebido basado en redes neuronales ligeras para reconocimiento automático de placas vehiculares.

Variables Dependientes:

- Tiempo promedio de validación vehicular (latencia del sistema).
- Precisión del reconocimiento (porcentaje de aciertos en inferencia).
- Generación correcta de señal digital de autorización hacia la etapa de potencia.
- Reducción porcentual del tiempo de acceso respecto al método manual.

Correspondencia entre Objetivos, Fases y Actividades

Para garantizar la trazabilidad del proyecto, el diseño metodológico se estructura en cuatro fases operativas. Cada fase agrupa una serie de actividades secuenciales diseñadas

para dar cumplimiento estricto a los objetivos específicos planteados. La Tabla 2 detalla esta alineación.

Tabla 2: Matriz de alineación metodológica: Objetivos, Fases y Actividades (Actualizada)

Objetivo Específico	Fase Metodológica	Actividades Principales
1. Implementar validación mediante sensores y redes neuronales embebidas.	Fase 1: Diseño de Arquitectura y Hardware	A1.1 Selección de la plataforma embebida. A1.2 Selección de la red de sensores. A1.3 Diseño mecánico y ensamblaje profesional (3D/PCB). A1.4 Propuesta de escalabilidad fotovoltaica.
2. Desplegar modelo de reconocimiento capaz de activar actuador de potencia.	Fase 2: Modelado TinyML y Señalización	A2.1 Estrategia de curaduría y minería de datos masivos. A2.2 Entrenamiento y optimización en Edge Impulse. A2.3 Diseño de la etapa de señalización visual (LED).
3. Diseñar módulo de gestión de trazabilidad segura y confiable.	Fase 3: Implementación de Trazabilidad	A3.1 Configuración de lista blanca en memoria local. A3.2 Registro de eventos y almacenamiento de logs en SD.
Validación general del sistema frente a variables dependientes.	Fase 4: Pruebas, Validación y Evaluación	A4.1 Ejecución de pruebas en entorno controlado (Sede Centro). A4.2 Análisis estadístico comparativo vs. sistema manual.

Fase 1: Diseño de Arquitectura y Hardware

Esta fase abarca la estructuración física del prototipo, priorizando dispositivos que cumplan con las restricciones de procesamiento en el borde (*Edge Computing*) y garantizando un acabado industrial.

Actividad 1.1: Selección de la plataforma embebida. Para garantizar la viabilidad del procesamiento de imágenes en el borde, se definieron criterios de evaluación específicos para visión artificial y redes neuronales, descartando parámetros de instrumentación convencional que no son críticos para este prototipo.

Se evaluaron tres alternativas tecnológicas utilizando una escala cuantitativa de 1 (desempeño bajo) a 5 (desempeño alto), como se detalla en la Tabla 3. Los criterios evaluados fueron:

- **Costo de implementación:** Accesibilidad económica para garantizar escalabilidad.
- **Memoria RAM/PSRAM:** Capacidad para almacenar el *framebuffer* y los tensores del modelo.
- **Hardware de Visión:** Disponibilidad de cámara integrada para evitar latencia de transmisión.
- **Soporte TinyML:** Compatibilidad oficial con plataformas como *Edge Impulse*.
- **Eficiencia Energética:** Consumo de potencia para operar de forma autónoma.

Tabla 3: Matriz de decisión para la selección de la plataforma embebida

Plataforma	Costo	Memoria (RAM)	Hardware de Visión	Soporte TinyML	Eficiencia Energéti- ca	Puntaje Total
Raspberry Pi 4	1	5	3	4	2	15
Arduino Nano 33 BLE	3	2	2	5	5	17
ESP32-CAM	5	4	5	5	4	23

El análisis cuantitativo evidencia que el **ESP32-CAM** obtiene el mayor puntaje (23 puntos). Su integración nativa del sensor OV2640, su memoria PSRAM externa y su compatibilidad total para exportar librerías desde *Edge Impulse* lo consolidan como la plataforma idónea, superando el alto consumo de la Raspberry Pi y las limitaciones visuales del Arduino Nano.

Actividad 1.2: Selección de la red de sensores de activación. Para evitar que el modelo de *TinyML* procese imágenes continuamente y sature el microcontrolador, se requiere un sensor de proximidad que active la cámara únicamente cuando un vehículo esté en posición. Se seleccionó el **sensor infrarrojo fotoeléctrico E18-D80NK**, el cual ofrece un rango de detección ajustable, inmunidad a la luz solar moderada y entrega una señal digital limpia directamente a los pines del microcontrolador.

Actividad 1.3: Diseño mecánico y ensamblaje profesional. Para garantizar una presentación técnica de alto nivel que prescinda por completo de obras civiles e instalaciones invasivas, el hardware no se presentará en placas de pruebas (protoboard). Todos los componentes se soldarán sobre una placa fenólica (baquelita perforada) o circuito impreso (PCB). Adicionalmente, se realizará el modelado CAD 3D de una carcasa y base estructural tipo tótem, la cual será fabricada mediante impresión 3D para alojar y proteger el microcontrolador, la cámara y la fuente de alimentación, logrando un aspecto profesional e industrial.

Actividad 1.4: Propuesta de escalabilidad energética (Sistema Fotovoltaico). Como parte de la proyección de escalabilidad y autonomía del prototipo, se contempla la futura integración de un sistema de alimentación fotovoltaica. Aunque en la fase de Producto Mínimo Viable (MVP) el sistema operará con una fuente de alimentación de corriente continua estándar (5V/2A) debido a restricciones de tiempo y presupuesto, el diseño mecánico y estructural dejará la provisión física para un panel solar.

Este enfoque de nodo autónomo (*Off-Grid*) elimina la necesidad de realizar acometidas eléctricas y obras civiles en los puntos de acceso remotos de la universidad. Para el diseño en software CAD, se dimensionó un panel monocristalino de 20W (450 mm×350 mm×25 mm). Este panel alimentaría un controlador de carga PWM acoplado a una batería de respaldo (por ejemplo, ácido-plomo de 12V 7Ah), garantizando la operación continua del microcontrolador y el sensor durante las horas nocturnas o de baja radiación.

Para reducir el voltaje de los 12V de la batería a los 5V requeridos por el ESP32-CAM, el circuito integrará un módulo reductor (Step-Down) LM2596. A continuación, en la Tabla 4, se presenta una proyección de costos estimada para esta mejora futura:

Tabla 4: Proyección de costos para escalabilidad con sistema fotovoltaico autónomo

Componente	Cantidad	Valor Unitario (COP)	Valor Total (COP)
Panel Solar Monocristalino (20W, 12V)	1	\$ 85,000	\$ 85,000
Controlador de Carga Solar (PWM 10A)	1	\$ 35,000	\$ 35,000
Batería Seca Recargable (12V, 7Ah)	1	\$ 65,000	\$ 65,000
Módulo Reductor Step-Down LM2596	1	\$ 8,000	\$ 8,000
Estructura de fijación y cableado	1	\$ 25,000	\$ 25,000
Costo Total Estimado			\$ 218,000

Fase 2: Modelado TinyML y Etapa de Señalización

En esta etapa se desarrolla el núcleo inteligente del sistema, abarcando la consolidación del conjunto de datos (*dataset*), el entrenamiento de la red neuronal y la capacidad de

accionar el entorno físico tras una lectura exitosa.

Actividad 2.1: Estrategia de curaduría y recolección de datos. Para el entrenamiento del modelo de visión artificial, se estructuró un conjunto de datos (*dataset*) compuesto por 531 imágenes. Para garantizar la robustez de la red neuronal y evitar sesgos, se empleó una estrategia de recolección mixta:

- **Imágenes de repositorio (80 % aprox.):** Se extrajeron alrededor de 430 imágenes etiquetadas desde el repositorio especializado Roboflow Universe (formato YOLOv5 PyTorch). Estas imágenes aportan variabilidad en tipografías, ángulos e iluminación.
- **Imágenes propias (20 % aprox.):** Se capturaron cerca de 100 fotografías reales utilizando un dispositivo móvil de alta resolución. Estas imágenes fueron posteriormente redimensionadas por la plataforma para enseñar a la red a reconocer el entorno real y las texturas locales.




Figura 1: Interfaz de adquisición de datos en Edge Impulse mostrando el etiquetado (bounding boxes) de las placas de motocicletas.

Nota. Captura del entorno de trabajo propio evidenciando el total de 531 ítems recolectados.

Actividad 2.2: Entrenamiento y optimización en Edge Impulse. El procesamiento de los datos y la configuración del modelo de aprendizaje automático se ejecutaron mediante

la plataforma *Edge Impulse*. El flujo de trabajo (*Impulse Design*) se configuró de la siguiente manera:

- **Bloque de Imagen:** Las imágenes se redimensionaron a una resolución de 96x96 píxeles en escala de grises (*Grayscale*). Esta decisión técnica es crucial para disminuir drásticamente el consumo de memoria RAM del microcontrolador sin perder los contrastes necesarios para leer una placa.
- **Bloque de Detección de Objetos:** Se seleccionó la arquitectura **FOMO (Faster Objects, More Objects)**. Este algoritmo es altamente eficiente para dispositivos de borde, permitiendo detecciones rápidas con una huella de memoria mínima.

Finalmente, el modelo fue cuantizado (convirtiendo los pesos de punto flotante de 32 bits a enteros de 8 bits - Int8), lo que asegura que el archivo resultante sea lo suficientemente ligero para ejecutarse en el ESP32-CAM.




Figura 2: Configuración del bloque de procesamiento y detección de objetos (FOMO) optimizado para el microcontrolador.

Actividad 2.3: Diseño de la etapa electrónica y señalización visual. Una vez el modelo genera una inferencia positiva (placa reconocida y validada), el microcontrolador debe interactuar con el mundo físico. Esta actividad consiste en el diseño de un circuito de acople que integre un indicador lumínico (LED de alta luminosidad). Este diodo actuará

como semáforo y prueba física de validación, encendiéndose para simular la señal de paso o apertura de talanquera, lo que permitirá demostrar la funcionalidad total del sistema ante los evaluadores sin requerir actuadores mecánicos a gran escala.

Fase 3: Implementación del Módulo de Trazabilidad

Para dar respuesta a la necesidad de auditoría institucional sin depender de infraestructuras en la nube, se diseña un sistema de registro local.

Actividad 3.1: Configuración de lista blanca. Se programará una estructura de datos en la memoria local del dispositivo que contenga las credenciales (placas) autorizadas, garantizando que la validación ocurra en milisegundos sin latencia de red.

Actividad 3.2: Registro de eventos (Logs). Se implementará una rutina que, tras cada evento de lectura, guarde un registro con el resultado de la inferencia, la placa detectada y la estampa de tiempo, almacenándolo en una memoria SD vinculada al sistema embebido.

Fase 4: Pruebas, Validación y Evaluación

La fase final consolida los resultados experimentales para responder a la pregunta de investigación.

Actividad 4.1: Pruebas en entorno controlado. Se realizarán iteraciones de validación (mínimo 30 pruebas sistemáticas) utilizando vehículos autorizados y no autorizados. Se documentarán variables como el nivel de confianza arrojado por el modelo, los falsos positivos/negativos y el tiempo de ejecución de la inferencia directamente en el puerto serial del microcontrolador.

Actividad 4.2: Evaluación comparativa de eficiencia. Se calculará la estadística descriptiva de los tiempos de respuesta del prototipo automatizado. Estos datos se con-

trastarán matemáticamente contra los 21 a 45 segundos promedio que toma actualmente el procedimiento manual, permitiendo cuantificar la mejora porcentual en la eficiencia operativa del ingreso vehicular a la institución.




Figura 3: Algoritmo lógico de reconocimiento y control de acceso.

Nota. Elaboración propia (2026), en Lucidchart.

Resultados Preliminares: Entrenamiento del Modelo TinyML

Análisis de las métricas del modelo

Luego del proceso de diseño y entrenamiento en la plataforma Edge Impulse, el modelo de inteligencia artificial fue evaluado utilizando el conjunto de datos de validación (*Validation Set*). Las métricas obtenidas con el modelo cuantizado (Int8), el cual es fundamental para garantizar su futura ejecución dentro de las restricciones de memoria del microcontrolador ESP32-CAM, son las siguientes:

- **F1-Score:** 0.90 (90 %)
- **Precisión (Precision):** 0.86 (86 %)
- **Sensibilidad (Recall):** 0.94 (94 %)




Figura 4: Métricas de validación y matriz de confusión del modelo cuantizado (Int8).

Nota. Se observa un F1-Score del 90.4 % y el consumo proyectado de memoria RAM (119.4K) que certifica su viabilidad para el ESP32-CAM.




Figura 5: Curva de pérdida (Loss) durante el entrenamiento de la red neuronal a lo largo de 60 épocas.

Nota. La convergencia simultánea y estabilización de las curvas de entrenamiento y validación demuestra un aprendizaje estable, descartando el fenómeno de sobreajuste (overfitting).

Para alcanzar estos resultados y mitigar el riesgo de sobreajuste (*overfitting*), se implementó la técnica de *Data Augmentation*. Esta estrategia consistió en aplicar ruido digital de forma aleatoria, variaciones de brillo y recortes (*cropping*) a las imágenes originales, permitiendo que la red neuronal generalice las características geométricas de las placas ante diversas condiciones lumínicas.

Validación lógica y próximos pasos

Los resultados obtenidos en esta fase validan matemáticamente la arquitectura algorítmica del sistema. El F1-Score del 90 % demuestra que el modelo de detección de objetos (*FOMO - Faster Objects, More Objects*) es viable para la tarea de reconocimiento vehicular utilizando imágenes de baja resolución.

Como siguiente paso dentro de la ruta metodológica, se proyecta la fase de desplie-

gue en el hardware (*Deployment*). Esto consistirá en exportar el modelo cuantizado como una librería de C++ para ser integrado y ejecutado directamente en el microcontrolador ESP32-CAM. Una vez cargado el *firmware*, se procederá a realizar las pruebas físicas de funcionamiento en tiempo real para medir variables como la latencia de inferencia y la correcta activación de la etapa electrónica de señalización.

Presupuesto del Prototipo

Para la ejecución del Producto Mínimo Viable (MVP), se ha diseñado un presupuesto optimizado que refleja la viabilidad económica del proyecto. A diferencia de los sistemas comerciales, este prototipo utiliza componentes de bajo costo y alta eficiencia. En la Tabla 5 se detallan los costos de los insumos principales:

Tabla 5: Presupuesto estimado para el prototipo funcional (MVP)

Componente	Cantidad	Valor Unitario	Valor Total
Microcontrolador ESP32-CAM (con cámara)	1	\$ 60,000	\$ 60,000
Sensor Infrarrojo E18-D80NK	1	\$ 22,000	\$ 22,000
Módulo Relé de 1 canal (5V)	1	\$ 8,500	\$ 8,500
Placa Fenólica y conectores	1	\$ 15,000	\$ 15,000
Insumos Impresión 3D (Filamento PLA)	1	\$ 20,000	\$ 20,000
Fuente de poder 5V/2A	1	\$ 18,000	\$ 18,000
Inversión Total Prototipo			\$ 143,500

Cronograma de Actividades

El desarrollo del proyecto se proyecta en un periodo de 8 semanas, distribuidas para cubrir desde la adquisición de datos hasta la validación final. La Tabla 6 muestra la

distribución temporal de las fases metodológicas:

Tabla 6: Cronograma de ejecución del proyecto (Semanas)

Actividad / Semana	1	2	3	4	5	6	7	8
A1. Diseño de Hardware y 3D	X	X						
A2. Recolección de imágenes (2000)		X	X	X				
A3. Entrenamiento en Edge Impulse				X	X			
A4. Programación y Trazabilidad local					X	X		
A5. Ensamblaje en PCB y Carcasa						X	X	
A6. Pruebas y Evaluación final							X	X

Referencias

- Alam, M. R., Saha, S., Bostami, M. B., Islam, M. S., Aadeeb, M. S., & Islam, A. K. M. M. (2023). A Survey on IoT Driven Smart Parking Management System: Approaches, Limitations and Future Research Agenda. *IEEE Access*, 11, 119523-119543. <https://doi.org/10.1109/ACCESS.2023.3327306>
- Al-Jaleel, B., & Al-Sultan, K. (2022). Traffic Capacity Analysis at Entrances and Exits of Universities: A Case Study. *Journal of Traffic and Logistics Engineering*, 10, 45-52.
- American Association of Motor Vehicle Administrators (AAMVA). (2021). *Best Practices Guide for Automated License Plate Recognition (ALPR) Systems* (inf. téc.). AAMVA.
- Bonomi, F., Milito, R., Zhu, J., & Addepalli, S. (2012). Fog Computing and Its Role in the Internet of Things. *Proceedings of the First Edition of the MCC Workshop on Mobile Cloud Computing*, 13-16. <https://doi.org/10.1145/2342509.2342513>
- Candelas Herias, F. A., Garcia Gomez, G. J., Pomares Baeza, J., Bravo, C. A. J., Delgado Rodriguez, A., Mateo Agullo, C. M., Mira Martinez, J. M., & Perez Alepuz, J. (2015). Experiencias sobre el uso de la plataforma Arduino en practicas de Automatizacion y Robotica. *XIII Jornadas de Redes de Investigacion en Docencia Universitaria*, 84-101. <https://dialnet.unirioja.es/servlet/articulo?codigo=5174477>
- Celaya-Echarri, M., Froiz-Miguez, I., Azpilicueta, L., Fraga-Lamas, P., Lopez-Iturri, P., Falcone, F., & Fernandez-Carames, T. M. (2020). Building Decentralized Fog Computing-Based Smart Parking Systems: From Deterministic Propagation Modeling to Practical Deployment. *IEEE Access*, 8, 117666-117688. <https://doi.org/10.1109/ACCESS.2020.3004745>
- Daniel, K. D., & Ram, D. S. (2022). Real-time embedded machine learning using TinyML and Edge Impulse. *2022 International Conference on Smart Systems and Inventive Technology (ICSSIT)*, 1-6. <https://doi.org/10.1109/ICSSIT53264.2022.9716341>

- Edge Impulse Inc. (2025). Edge Impulse Documentation [Accedido el 08 de noviembre de 2025]. <https://docs.edgeimpulse.com>
- Efthymiou, D., Chrysostomou, K., Morfoulaki, M., & Aifantopoulou, G. (2017). Electric vehicles charging infrastructure location: a genetic algorithm approach. *European Transport Research Review*, 9(27), 1-12. <https://doi.org/10.1007/s12544-017-0237-3>
- Federal Highway Administration (FHWA). (2019). *Traffic Analysis Toolbox Volume III: Guidelines for Applying Traffic Microsimulation Modeling Software* (inf. téc.) (Publication No. FHWA-HRT-04-040). U.S. Department of Transportation.
- Hossain, M. S. (2020). Edge Computing and Embedded Machine Learning: The Future of IoT. *IEEE Potentials*, 39(5), 27-33. <https://doi.org/10.1109/MPOT.2020.2980444>
- Leurent, F., & Windisch, E. (2011). Triggering the development of electric mobility: a review of public policies. *European Transport Research Review*, 3(64), 221-235. <https://doi.org/10.1007/s12544-011-0056-3>
- Macias Aleman, V. M. (1996). Automatización del acceso a los recursos documentales en bibliotecas universitarias: el caso de la Universidad de Las Palmas de Gran Canaria. *Sistemas de información. Balance de 12 años de jornadas y perspectivas de futuro: actas*, 1, 199-205. <https://dialnet.unirioja.es/servlet/articulo?codigo=1339387>
- Marshoodulla, S. Z., & Saha, G. (2024). SDIoT Park: A Data Analytics Framework for Smart Parking Using SDN-Based IoT. *IEEE Internet of Things Journal*, 11(11), 20030-20039. <https://doi.org/10.1109/JIOT.2024.3373133>
- Nguyen, D. D., et al. (2023). Deploying license plate recognition algorithms on edge computing devices. *IEEE Access*, 11, 15000-15012.
- Olivares, E. L. (2011). Estacionamiento Automatizado con Tecnología RFID. *Conciencia Tecnológica*, (42), 71-73. <https://dialnet.unirioja.es/servlet/articulo?codigo=3832418>
- Oloriz, M. G., Rissi, M., Fernandez, J. M. R., & Mason, M. R. (2022). La automatización de la certificación de títulos universitarios en Argentina como garantía del derecho al acceso a la información pública y la mejora en el uso de recursos. *Revista Academia*

- ℰ Negocios (RAN)*, 8(16), 155-162. <https://dialnet.unirioja.es/servlet/articulo?codigo=9385236>
- Satyanarayanan, M. (2017). The Emergence of Edge Computing. *Computer*, 50(1), 30-39. <https://doi.org/10.1109/MC.2017.9>
- Subash, S., & Narmadhai, N. (2025). Optimal location for electric vehicle charging station using multiobjective assessment method. *Sustainable Energy Research*, 12, 36-49. <https://doi.org/10.1007/s42108-025-00376-2>
- Valeo, J. P., Gregoracci, S., Seijas, L. M., & Etcheverry, J. A. (2020). Sistema automatizado de estacionamiento para patentes argentinas. *Investigación en la Enseñanza de la Electrónica*, 4(2), 107-113. <https://dialnet.unirioja.es/servlet/articulo?codigo=7750810>
- Warden, P., & Situnayake, D. (2020). *TinyML: Machine Learning with TensorFlow Lite on Arduino and Ultra-Low-Power Microcontrollers*. O'Reilly Media.
- Zheng, X., Feng, W., Wang, N., & Huhemandula. (2025). IoT-Enhanced Smart Parking Management With IncepDenseMobileNet for Improved Classification. *IEEE Access*, 13, 128838-128855. <https://doi.org/10.1109/ACCESS.2025.3589468>